

3.1 本证明参考课程ppt的大致证明，Fisher准则如下：

$$\max_w J_F(w) = \frac{(\tilde{m}_1 - \tilde{m}_2)^2}{\tilde{S}_1 + \tilde{S}_2}$$

又

$$\begin{aligned}\tilde{m}_1 - \tilde{m}_2 &= \frac{1}{N_1} \sum_{y_j \in Y_1} y_j - \frac{1}{N_2} \sum_{y_j \in Y_2} y_j = \frac{1}{N_1} \sum_{x \in D_1} w^T x - \frac{1}{N_2} \sum_{x \in D_2} w^T x = w^T m_1 - w^T m_2 \\ (\tilde{m}_1 - \tilde{m}_2)^2 &= |w^T(m_1 - m_2)|^2 = w^T(m_1 - m_2)(m_1 - m_2)^T w = w^T S_b w \\ \tilde{S}_1 + \tilde{S}_2 &= \sum_{y_j \in y_1} (y_j - \tilde{m}_1)(y_j - \tilde{m}_1)^T + \sum_{y_j \in y_2} (y_j - \tilde{m}_2)(y_j - \tilde{m}_2)^T \\ &= \sum_{x \in D_1} (w^T x - w^T m_1)(w^T x - w^T m_1)^T + \sum_{x \in D_2} (w^T x - w^T m_2)(w^T x - w^T m_2)^T \\ &= \sum_{x \in D_1} w^T (x - m_1)(x - m_1)^T w + \sum_{x \in D_2} w^T (x - m_2)(x - m_2)^T w = w^T S_w w\end{aligned}$$

于是Fisher准则可以化为：

$$J_F(w) = \frac{w^T S_b w}{w^T S_w w}$$

不妨令分母 $w^T S_w w = c \neq 0$, 最大化分子 $w^T S_b w$, 即：

$$\begin{aligned}\max w^T S_b w \\ s. t. w^T S_w w = c\end{aligned}$$

使用拉格朗日乘子法可得： $L(w, \lambda) = w^T S_b w - \lambda (w^T S_w w - c)$, 优化此函数得到：

Fisher线性判别最优投影方向为 $w^* \propto S_w^{-1} (m_1 - m_2)$

3.2 首先解释名词含义：参考百度百科

- **误差平方和**：误差平方和是根据n个观察值拟合适当的模型后，余下未能拟合部份称为**残差**，其中y平均表示n个观察值的平均值，所有n个残差平方之和称**误差平方和**。**作用**：衡量模型拟合效果的好坏，SSE越小说明模型拟合的效果越好。
- **决定系数 (R^2)**：对于单变量回归，即为 $R^2 = \frac{\text{Cov}(X,Y)}{S_X S_Y}$ 。对于多变量回归，
 $R^2 = \frac{SSR}{SST} = 1 - \frac{SSE}{SST}$
 其中，

$$\begin{aligned}SST &= \sum_{i=1}^n (y_i - \bar{y})^2 \\ SSR &= \sum_{i=1}^n (\hat{y}_i - \bar{y})^2\end{aligned}$$

作用：决定了模型的拟合效果，当决定系数取得最大值1的时候，说明模型拟合最好。

- **MAE 和 MAPE**：MAE是平均绝对误差，表示为 $MAE = \frac{1}{n} \sum_{i=1}^n |\hat{y}_i - y_i|$ ，MAPE是平均绝对百分比误差， $MAPE = \frac{100\%}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right|$ ，**作用**：用于衡量模型拟合的好坏，MAE越小拟合效果越好，当MAPE为0时，大于100%时说明模型有问题。

- **MSE 和 RMSE**: MSE是均方误差, 是参数估计值与参数真值之差平方的期望值:

$MSE = \frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2$ 。RMSE是均方根误差, 即MSE的算术平方根:

$$RMSE = \sqrt{MSE}$$

作用: 用于衡量模型拟合效果的好坏, 相比于其他系数消除了数据个数对于大小的影响, MSE越小说明拟合效果越好。

回归系数最能体现模型的准确性。

证明:

查阅[百度百科](https://baike.baidu.com/item/皮尔森相关系数)等网站可得皮尔森相关系数为:

$$r = \frac{N \sum x_i y_i - \sum x_i \sum y_i}{\sqrt{N \sum x_i^2 - (\sum x_i)^2} \sqrt{N \sum y_i^2 - (\sum y_i)^2}}$$

又,

$$R^2 = \frac{SSR}{SST} = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

代入:

$$\begin{aligned}\hat{y}_i &= \hat{\beta}_0 + \hat{\beta}_1 x_i \\ \bar{y} &= \hat{\beta}_0 + \hat{\beta}_1 \bar{x} \\ \hat{\beta}_1 &= \frac{N \sum x_i y_i - \sum x_i \sum y_i}{N \sum x_i^2 - (\sum x_i)^2}\end{aligned}$$

代入可得:

$$\begin{aligned}R^2 &= \frac{\sum_{i=1}^n (\hat{\beta}_1)^2 (x_i - \bar{x})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} = \left(\frac{N \sum x_i y_i - \sum x_i \sum y_i}{N \sum x_i^2 - (\sum x_i)^2} \right)^2 \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \\ &= \frac{N \sum x_i y_i - \sum x_i \sum y_i}{\left(N \sum x_i^2 - (\sum x_i)^2 \right) \left(N \sum y_i^2 - (\sum y_i)^2 \right)} = r^2\end{aligned}$$

3.3 以下证明参考了<https://blog.csdn.net/perryre/article/details/53678128>

3-3: Fisher 准则的结论 $w = \alpha N S_w^T (m_1 - m_2) \propto S_w^T (m_1 - m_2)$
 使用最小二乘法求解 MSE 得到: $a^* = (Y^T Y)^{-1} Y^T b$
 给定 $b = [N_1/N, N_2/N]$
 w_1 的样本集为: $x_1 = \{x_1^1, x_1^2, \dots, x_1^{N_1}\}$
 w_2 的样本集为: $x_2 = \{x_2^1, x_2^2, \dots, x_2^{N_2}\}$
 增广矩阵为: $Y = \begin{bmatrix} 1 & x_1^T \\ \vdots & \vdots \\ 1 & x_1^T \\ -1 & x_2^T \\ \vdots & \vdots \\ -1 & x_2^T \end{bmatrix} = \begin{bmatrix} e_1 & x_1 \\ -e_2 & x_2 \end{bmatrix}$
 其中 $e_1 = [1, \dots, 1]$, $e_2 = [1, \dots, 1]$, 增广系数可以表示为 $a = \begin{bmatrix} w_0 \\ w \end{bmatrix}$
 b 可以写作 $b = \begin{bmatrix} N_1/N \\ N_2/N \end{bmatrix} = \begin{bmatrix} N_1/N & e_1 \\ N_2/N & e_2 \end{bmatrix}$
 代入最优解 a^* : $\begin{bmatrix} e_1^T & -e_2^T \\ x_1^T & -x_2^T \end{bmatrix} \begin{bmatrix} e_1 & x_1 \\ -e_2 & x_2 \end{bmatrix} \begin{bmatrix} w_0 \\ w \end{bmatrix} = \begin{bmatrix} e_1^T & -e_2^T \\ x_1^T & -x_2^T \end{bmatrix} \begin{bmatrix} N_1/N & e_1 \\ N_2/N & e_2 \end{bmatrix}$
 $\Rightarrow \begin{bmatrix} e_1^T e_1 + e_2^T e_2 & e_1^T x_1 + e_2^T x_2 \\ x_1^T e_1 + x_2^T e_2 & x_1^T x_1 + x_2^T x_2 \end{bmatrix} \begin{bmatrix} w_0 \\ w \end{bmatrix} = \begin{bmatrix} N_1 e_1^T e_1 & -N_2 e_2^T e_2 \\ N_1 x_1^T e_1 & -N_2 x_2^T e_2 \end{bmatrix}$
 $S_i = \sum (x_i - m_i)(x_i - m_i)^T = \sum (x_i x_i^T - m_i x_i^T - x_i m_i^T + m_i m_i^T)$
 $= x_i^T x_i - 2 N_i m_i m_i^T + N_i m_i m_i^T = x_i^T x_i - N_i m_i m_i^T$
 $\sum m_i = \frac{1}{N} \sum x_i \Rightarrow$ 代入原式得 $x_i^T x_i - N_i m_i m_i^T$
 $\Rightarrow S_w = \sum_{i=1}^N (x_i^T x_i - N_i m_i m_i^T)$ 根据这个等式可以导出: $x_1^T x_1 + N_2 x_2 = S_w + N_1 m_1 m_1^T + N_2 m_2 m_2^T$
 $x_2^T e_2 = N_2 m_2$ 重新代入上面的大矩阵:
 $\begin{bmatrix} N_1 + N_2 & (N_1 m_1 + N_2 m_2)^T \\ N_1 m_1 + N_2 m_2 & S_w + N_1 m_1 m_1^T + N_2 m_2 m_2^T \end{bmatrix} \begin{bmatrix} w_0 \\ w \end{bmatrix} = \begin{bmatrix} N_1 N_1 - N_2 N_2 \\ N_1 N_1 m_1 - N_2 N_2 m_2 \end{bmatrix}$
 根据第一行可以算得 $N w_0 + (N_1 m_1 + N_2 m_2)^T w = 0$
 $w_0 = \frac{(N_1 m_1 + N_2 m_2)^T w}{N}$
 根据第二行和 w_0 的值可以得到:

$$\left(- \frac{(N_1 m_1 + N_2 m_2)(N_1 m_1 + N_2 m_2)^T}{N} \right) = \frac{1}{N} (-N_1^2 m_1 m_1^T - 2 N_1 N_2 m_1 m_2^T - N_2^2 m_2 m_2^T)$$

分为两项: 第一项: $-\frac{(N_1 m_1 + N_2 m_2)(N_1 m_1 + N_2 m_2)^T}{N} = \frac{1}{N} (-N_1^2 m_1 m_1^T - 2 N_1 N_2 m_1 m_2^T - N_2^2 m_2 m_2^T)$
 第二项: $N_1 m_1 m_1^T + N_2 m_2 m_2^T = \frac{1}{N} (N_1^2 m_1 m_1^T + N_1 N_2 m_1 m_2^T + N_1 N_2 m_2 m_1^T + N_2^2 m_2 m_2^T)$
 两项之和为: $\left(\frac{1}{N} S_w w + \frac{N_1 N_2}{N^2} (m_1 - m_2)(m_1 - m_2)^T w \right) = m_1 - m_2$
 又 $(m_1 - m_2)^T w$ 为常数: $\frac{N_1 N_2}{N^2} (m_1 - m_2)(m_1 - m_2)^T w = (1 - \alpha)(m_1 - m_2)$
 $\frac{1}{N} S_w w + (1 - \alpha)(m_1 - m_2) = (m_1 - m_2)$
 $S_w w = \alpha N (m_1 - m_2)$
 最后得到 $w = \alpha N S_w^T (m_1 - m_2)$
 $w^* = S_w^T (m_1 - m_2)$
 故方向一致, 两种不同的方法

3.4 以下证明参考了课件

罗杰思特回归需要优化的是最大似然函数: $L(w) = \prod_{j=1}^N P(y_j | x_j) = \prod_{j=1}^N \theta(y_j w^T x_j)$

等价于优化:

$$E(w) = -\frac{1}{N} \ln(L(w)) = -\frac{1}{N} \ln \left(\prod_{j=1}^N \theta(y_j w^T x_j) \right)$$

$$= \frac{1}{N} \sum_{j=1}^N \ln(1 + e^{-y_j w^T x_j})$$

求梯度

$$\begin{aligned}
\nabla E &= \frac{1}{N} \sum_{j=1}^N \nabla \left(\ln \left(1 + e^{-y_j w^T x_j} \right) \right) \\
&= \frac{1}{N} \sum_{j=1}^N \frac{e^{-y_j w^T x_j}}{1 + e^{-y_j w^T x_j}} y_j x_j \\
&= -\frac{1}{N} \sum_{j=1}^N \left(\frac{1}{1 + e^{y_j w^T x_j}} \right) y_j x_j
\end{aligned}$$